Máster Universitario en Ingeniería Informática

Tratamiento Inteligente de Datos

PRÁCTICA 1: Preprocesamiento

Accidentes

UNIVERSIDAD DE GRANADA

Carlos Santiago Sánchez Muñoz

Grupo de prácticas 1 - Jueves

Email: carlossamu7@correo.ugr.es

4 de noviembre de 2020

Índice

1. Descripción del problema **2**
1.1. Atributos imputados de la base de datos 2
1.2. Construcción de la variable a predecir 3

2. Discretización **4**

3. Valores perdidos **6**
3.1. Imputando valores con media y moda 6
3.2. Eliminando instancias 6
3.3. Eliminando atributos 7

4. Selección de características **8**

5. Selección de instancias **9**
5.1. Muestreo 9
5.2. Balanceando los datos 9

1. Descripción del problema

En EE.UU., el General Estimate System (GES) es un componente del National Automotive Sampling System (NASS) mantenido por la Administración Nacional de Seguridad del Tráfico en Carreteras. El GES obtiene sus datos de una muestra representativa a nivel nacional de los aproximadamente 6,4 millones de accidentes informados por la policía que se producen anualmente. Estos accidentes incluyen aquellos que resultan mortales o causan lesiones y los relacionados con daños materiales. Al restringir la atención a los accidentes informados por la policía, el GES se concentra en los accidentes de mayor preocupación para la comunidad de seguridad vial y el público en general. GES se utiliza para identificar áreas con problemas de seguridad vial, proporcionar una base para iniciativas de información al consumidor y normativas, así como facilitar el análisis de costes y beneficios de las iniciativas de seguridad en carretera.

En esta práctica, utilizaremos como ejemplo el conjunto de datos tomado como muestra en el año 2001 (55.964 datos). Para facilitar las pruebas durante la realización de la práctica, dada la cantidad de datos, se facilitará el archivo completo `.xls`, y una versión con un número reducido de instancias. Ambos archivos `.xls` contienen dos hojas: una, con la descripción de las variables y los posibles valores que pueden tomar, y, otra, con los datos recogidos.

El objetivo del problema es predecir la gravedad del daño causado en el accidente en función de una serie de características como la ingesta de alcohol del conductor, hora del accidente, condición de la carretera, etc. Este tipo de predicción podría ser útil, por ejemplo, para priorizar la dotación de recursos en respuesta a un accidente. Sin embargo, los datos disponibles presentan importantes deficiencias (valores perdidos, características con excesivas categorías, características e instancias prescindibles, etc.) que sugieren la necesidad de ser preprocesados antes de aplicar otras técnicas de Minería de Datos.

1.1. Atributos imputados de la base de datos

Algunos atributos de esta base de datos tienen valores perdidos y existe un atributo análogo (normalmente contiene un `_I`). A la hora de hacer cualquier tarea, ya sea preprocesar o aplicar una técnica de clasificación se debe usar una sola de esas variables, nunca ambas. Las parejas de estos atributos son las siguientes:

Variable	**Variable imputada**	**Variable**	**Variable imputada**
WEEKDAY	WKDY_I	SUR_COND	SURCON_I
HOUR	HOUR_I	TRAF_CON	TRFCON_I
MAN_COL	MANCOL_I	SPD_LIM	SPDLIM_H
REL_JCT	RELJCT_I	LGHT_CON	LGTCON_I
ALIGN	ALIGN_I	WEATHER	WEATHR_I
PROFILE	PROFIL_I	ALCOHOL	ALCHL_I

Tabla 1: Tabla de parejas variable-variable imputada

En mi caso manejaré dos conjuntos de datos a la vez, los normales y los imputados. A continuación muestro la lectura de estos datos y como se distingue entre la base de datos

con atributos sin imputar y los imputados.

```
""" Lectura de datos. Devuelve dos df, uno de ellos con las columnas imputadas.
- mini (op): indica si leer 'accidentes_mini'. Por defecto 'True'.
"""
def read_data(mini=True):
    if(mini):
        df = pd.read_excel(r'accidentes_mini.xls', sheet_name='datos')
    else:
        df = pd.read_excel(r'accidentes.xls', sheet_name='datos')

    df_I = df.copy()
    df = df.drop(columns = ['WKDY_I', 'HOUR_I', 'MANCOL_I', 'RELJCT_I', 'ALIGN_I',
                  'PROFIL_I', 'SURCON_I', 'TRFCON_I', 'SPDLIM_H',
                  'LGTCON_I', 'WEATHR_I', 'ALCHL_I'])
    df_I = df_I.drop(columns = ['WEEKDAY', 'HOUR', 'MAN_COL', 'REL_JCT', 'ALIGN',
                  'PROFILE', 'SUR_COND', 'TRAF_CON', 'SPD_LIM',
                  'LGHT_CON', 'WEATHER', 'ALCOHOL'])
    if(IMPRIME_INFO):
        print()
        print(df.info())
        print()
        print(df_I.info())
    return df, df_I
```

1.2. Construcción de la variable a predecir

La construcción de esta variable, la que predice el accidente, se tiene que hacer en función de las variables `FATALITIES`, `INJURY_CRASH` y `PRPTYDMG_CRASH`. Tras hacer algunas pruebas desde `Python` y visualizar estas variables me di cuenta de que nunca las tres estaban activas. Por tanto sólo hay tres tipos de accidentes: daños materiales, lesiones y accidente mortal.

He llamado a dicha variable `CRASH_TYPE`. ¿Cómo construirla eficientemente en función de las tres anteriores? Pues bien las tres anteriores toman el valor `0` o `1` y como mucho sólo una está activada a la vez. La construcción más sencilla es la siguiente:

$$\texttt{CRASH\_TYPE} = 0 \cdot \texttt{PRPTYDMG\_CRASH} + 1 \cdot \texttt{INJURY\_CRASH} + 2 \cdot \texttt{FATALITIES}$$

Trasladando esto a código y eliminando posteriormente dichas tres variables sería así:

```
""" Construyendo la variable de clase 'CRASH_TYPE'. Devuelve el df.
- df: dataframe.
"""
def construct_class_variable(df):
    df['CRASH_TYPE'] = df['INJURY_CRASH'] + 2*df['FATALITIES']
    return df.drop(columns = ['PRPTYDMG_CRASH', 'INJURY_CRASH', 'FATALITIES'])
```

2. Discretización

Algunas características contienen valores discretos según una escala ordenada y con suficiente cardinalidad como para plantearse la conveniencia de discretizarlos. De esto modo, al reducirlo a un menor número de posibles valores, simplificamos la clasificación haciendo también más sencillo el proceso de aprendizaje.

La primera variable que podemos discretizar es `HOUR`. Si la hora está en $[7, 14]$ diremos que es por la mañana y le asignaremos un `0`. Si está en $[15, 23]$ diremos que es por la tarde y le asignaremos un `1` y si está fuera de esos intervalos es por la noche y le asignaremos un `2`.

```
""" Discretizando la variable 'HOUR'. Devuelve el df.
- df: dataframe.
- imputed (op): si es el imputado. Por defecto 'False'.
"""
def discretize_HOUR(df, imputed=False):
    if imputed:
        atribute = 'HOUR_I'
    else:
        atribute = 'HOUR'
    for i in range(len(df[atribute])):
        # Si es por la mañana asigno un 0
        if(df[atribute][i]>=7 and df[atribute][i]<=14):
            df[atribute][i] = 0
        # Si es por la tarde asigno un 1
        elif(df[atribute][i]>=15 and df[atribute][i]<=23):
            df[atribute][i] = 1
        # Si es por la noche o es desconocido asigno un 2
        else:
            df[atribute][i] = 2
    return df
```

La segunda variable que se va a discretizar es `WEEKDAY`, el día de la semana. Si es entre semana (el número del día está en $[2, 6]$) le asigno un `0` y si es en fin de semana (fuera de ese intervalo) le asigno un `1`.

```
""" Discretizando la variable 'WEEKDAY'. Devuelve el df.
- df: dataframe.
- imputed (op): si es el imputado. Por defecto 'False'.
"""
def discretize_WEEKDAY(df, imputed=False):
    if imputed:
        atribute = 'WKDY_I'
    else:
        atribute = 'WEEKDAY'
    for i in range(len(df[atribute])):
        # Si es entre semana asigno 0
        if(df[atribute][i]>=2 and df[atribute][i]<=6):
            df[atribute][i] = 0
        # Si es entre semana asigno 1
        else:
            df[atribute][i] = 1
    return df
```

La última variable que se va a discretizar es la velocidad, `SPD_LIM`. Voy a distinguir entre una velocidad baja (menos de 40) a la que le asignaré un `0`, una velocidad media (en el intervalo $[44, 66)$) en donde asigno un `1` y por último velocidad alta (mayor o igual a 66) en donde asigno un `2`.

```
""" Discretizando la variable 'SPD_LIM'. Devuelve el df.
- df: dataframe.
- imputed (op): si es el imputado. Por defecto 'False'.
"""
def discretize_SPD_LIM(df, imputed=False):
    if imputed:
        atribute = 'SPDLIM_H'
    else:
        atribute = 'SPD_LIM'
    for i in range(len(df[atribute])):
        # Si es menor a 40 asigno 0
        if(df[atribute][i]<40):
            df[atribute][i] = 0
        # Si entre 40 y 65 asigno 1
        elif(df[atribute][i]>=40 and df[atribute][i]<66):
            df[atribute][i] = 1
        # Si es mayor a 65 asigno 2
        else:
            df[atribute][i] = 2
    return df
```

Estas tres discretizaciones se las voy a aplicar al conjunto de datos imputado.

3. Valores perdidos

3.1. Imputando valores con media y moda

```
""" Imputando valores con la media. Devuelve el df.
- df: dataframe.
"""
def imput_mean(df):
    atr_imputed = ['WEEKDAY', 'HOUR', 'MAN_COL', 'INT_HWY', 'REL_JCT', 'ALIGN',
                   'PROFILE', 'SUR_COND', 'TRAF_CON', 'SPD_LIM', 'LGHT_CON',
                   'WEATHER', 'PED_ACC', 'PED_ACC', 'ALCOHOL']
    unknown_val = [9, 99, 99, 9, 99, 9, 9, 9, 99, 99, 9, 9, 9998, 9999, 9]
    for i in range(len(atr_imputed)):
        mean = int(df[atr_imputed[i]].mean())
        if(IMPRIME_INFO):
            print("  Cambiando en {} el valor {} por su media: {}"
                  .format(atr_imputed[i], unknown_val[i], mean))
        df[atr_imputed[i]] =
            df[atr_imputed[i]].replace(to_replace = unknown_val[i], value = mean)
    return df

""" Imputando valores con la moda. Devuelve el df.
- df: dataframe.
"""
def imput_mode(df):
    atr_imputed = ['WEEKDAY', 'HOUR', 'MAN_COL', 'INT_HWY', 'REL_JCT', 'ALIGN',
                   'PROFILE', 'SUR_COND', 'TRAF_CON', 'SPD_LIM', 'LGHT_CON',
                   'WEATHER', 'PED_ACC', 'PED_ACC', 'ALCOHOL']
    unknown_val = [9, 99, 99, 9, 99, 9, 9, 9, 99, 99, 9, 9, 9998, 9999, 9]
    for i in range(len(atr_imputed)):
        mode = int(df[atr_imputed[i]].mode())
        if(IMPRIME_INFO):
            print("  Cambiando en {} el valor {} por su moda: {}"
                  .format(atr_imputed[i], unknown_val[i], mode))
        df[atr_imputed[i]] =
            df[atr_imputed[i]].replace(unknown_val[i], mode)
    return df
```

3.2. Eliminando instancias

```
""" Borrando intancias con valores desconocidos. Devuelve el df.
- df: dataframe.
"""
def delete_instances(df):
    # No considero SPEED_LIM que siempre es desconocido.
    atr_imputed = ['WEEKDAY', 'HOUR', 'MAN_COL', 'INT_HWY', 'REL_JCT', 'ALIGN',
                   'PROFILE', 'SUR_COND', 'TRAF_CON', 'LGHT_CON',
                   'WEATHER', 'PED_ACC', 'PED_ACC', 'ALCOHOL']
    unknown_val = [9, 99, 99, 9, 99, 9, 9, 9, 99, 9, 9, 9998, 9999, 9]
    to_delete = []
    for i in range(len(df)):
        cond = False
        for j in range(len(atr_imputed)):
            if(df.iloc(0)[i][atr_imputed[j]]==unknown_val[j]):
                cond = True
                to_delete.append(i)
    if(IMPRIME_INFO):
        print("úNmero de instancias a eliminar: {}".format(len(to_delete)))
    df = df.drop(to_delete, axis=0)
    df=df.reset_index()
    del df['index']
    return df
```

3.3. Eliminando atributos

```
""" Borrando ícaractersticas que contienen valores desconocidos. Devuelve el df.
- df: dataframe.
"""
def delete_attributes(df):
    # No considero SPEED_LIM que siempre es desconocido.
    atr_imputed = ['WEEKDAY', 'HOUR', 'MAN_COL', 'INT_HWY', 'REL_JCT', 'ALIGN',
                   'PROFILE', 'SUR_COND', 'TRAF_CON', 'SPD_LIM', 'LGHT_CON',
                   'WEATHER', 'PED_ACC', 'ALCOHOL']
    if(IMPRIME_INFO):
        print("úNmero de atributos a eliminar: {}".format(len(atr_imputed)))
    df = df.drop(columns = atr_imputed)
    return df
```

4. Selección de características

```
""" Selecciona las ícaractersticas ám relevantes usando Recursive Feature Elimination (RFE).
Devuelve el df.
- X: datos de entrada.
- y: etiquetas.
- n_features: únmero de ícaractersticas.
- feature_cols: nombres de las columnas.
"""
def select_features(X, y, n_features, feature_cols):
    # Selección de características
    selector = RFE(DecisionTreeClassifier(), n_features)
    selector = selector.fit(X, y)
    to_select = selector.support_
    to_delete_attributes = []
    features = []
    for i in range(len(feature_cols)):
        if(not to_select[i]):
            to_delete_attributes.append(feature_cols[i])
        else:
            features.append(feature_cols[i])
    if(IMPRIME_INFO):
        print("\nNum Features: %s" %(selector.n_features_))
        print("Selected Features: %s" %(selector.support_))
        print("Feature Ranking: %s" %(selector.ranking_))
        print(to_delete_attributes)
    return X.drop(columns = to_delete_attributes), features
```

5. Selección de instancias

5.1. Muestreo

```
""" Seleccionando intancias con muestreo aleatorio. Devuelve el df.
- df: dataframe.
- frac: ófraccin entre 0 y 1 de los datos a coger.
"""
def select_instances(df, frac):
    df = df.sample(frac=frac, random_state=1)
    if(IMPRIME_INFO):
        print(" ó Seleccin de {} instancias aleatorias".format(df.shape[0]))
    df=df.reset_index()
    del df['index']
    return df
```

5.2. Balanceando los datos

```
""" Borra una clase para testear el desbalanceo de datos.
- df: dataframe.
- clas: clase a borrar.
"""
def delete_class(df, clas):
    to_delete = []
    for i in range(len(df)):
        if(df.iloc(0)[i]["CRASH_TYPE"]==clas):
            to_delete.append(i)
    if(IMPRIME_INFO):
        print("úNmero de instancias a eliminar: {}".format(len(to_delete)))
    df = df.drop(to_delete, axis=0)
    df=df.reset_index()
    del df['index']
    return df

""" Elige aleatoriamente tantas instancias de la clase distinta a la clase '2' como instancias tiene
- df: dataframe.
"""
def select_n_instances(df):
    #seleccionamos un subconjunto
    num = df.groupby(['CRASH_TYPE']).size()[2] # número de instancias de la clase 2
    df_copy = delete_class(df, 2)
    df_copy = df_copy.sample(n=num, random_state=1)
    if(IMPRIME_INFO):
        print("óSeleccin de {} instancias aleatorias".format(df_copy.shape[0]))
    df_copy=df_copy.reset_index()
    del df_copy['index']
    df_2 = df[df["CRASH_TYPE"] == 2]
    df = pd.concat([df_2, df_copy])
    df = df.reset_index()
    del df['index']
    return df
```

En unas gráficas de barras lo podemos apreciar mejor:

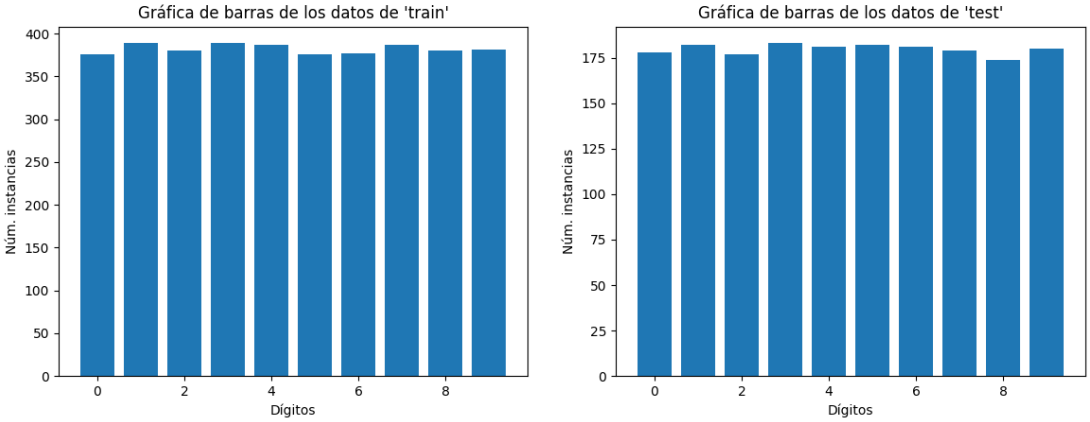

(a) Train (b) Test

Imagen 1: Gráficas de barras de los datos